

Reconstrucción y eliminación de ruido en imágenes con K-SVD: una adaptación didáctica

Proyecto académico — Matemáticas Computacionales, INAOE

Resumen

Se implementa un ciclo K-SVD propio (codificación dispersa con `orthogonal_mp` de scikit-learn y actualización de átomos con `numpy.linalg.svd`) para aprender un diccionario de 128 átomos a partir de 1500 parches 8×8 de la imagen *camera*. El diccionario se usa para reconstruir la imagen *coins* (no vista en entrenamiento), limpia y con ruido gaussiano $\sigma = 20/255$, con dispersión $T_0 \in \{2, 4, 8\}$. La mejor reconstrucción de la imagen ruidosa alcanza 26.12 dB ($T_0 = 4$) frente a 22.09 dB de la entrada ruidosa. Es una adaptación pequeña y didáctica; no es una réplica de los artículos originales ni pretende superar el estado del arte.

1 Introducción y fundamento

Un parche $x \in \mathbb{R}^{64}$ se modela como combinación lineal de pocas columnas (átomos) de un diccionario $D \in \mathbb{R}^{64 \times K}$: $x \approx D\alpha$ con $\|\alpha\|_0 \leq T_0$. K-SVD [1] aprende D alternando (i) codificación dispersa de los ejemplos con el diccionario actual y (ii) actualización de los átomos uno por uno, junto con los coeficientes que los usan. Elad y Aharon [2] usan esta idea para eliminar ruido: parches 8×8 con solapamiento, diccionario de 64×256 (inicializado con un DCT redundante), OMP con criterio de error ($C = 1.15$), $J = 10$ iteraciones de K-SVD y un promedio final con la imagen ruidosa ponderado por $\lambda = 30/\sigma$.

Este proyecto toma una versión **reducida y didáctica**: diccionario entrenado en una imagen limpia distinta a la de prueba, número fijo de átomos T_0 (no criterio de error), sin el término de fidelidad λ y con una sola imagen de prueba y una sola realización de ruido.

2 Datos y parches

- Entrenamiento: `skimage.data.camera()` a 256×256 ; prueba: `skimage.data.coins()` a 128×128 (`img_as_float64`, `resize` con `anti_aliasing=True`, `preserve_range=True`).
- Parches 8×8 , paso 4, recorrido por filas y luego columnas, aplanado en orden C, incluyendo el último inicio válido. Camera produce 3969 parches y coins 961.
- Cada parche se centra (se resta su media, que se guarda); no se normaliza por su norma.
- Se filtran parches con norma centrada $\leq 10^{-8}$ y se eligen 1500 sin reemplazo (RNG 42).
- Prueba de ida y vuelta (extraer y reensamblar): error máximo $1.1e-16$ (camera) y $1.1e-16$ (coins), por debajo de 10^{-10} .

3 Método

3.1 Codificación dispersa

$A = \arg \min \|Z - DA\|_F$ s.a. $\|a_i\|_0 \leq T$ se aproxima con OMP de scikit-learn (`orthogonal_mp(D, Z, n_nonzero_coefs=T)`), sin intercepto; las señales con norma $\leq 10^{-8}$ reciben coeficientes cero. T es un máximo: OMP puede detenerse antes si el residual se anula.

3.2 Actualización K-SVD

Para cada átomo j , con D y A ya actualizados por los átomos anteriores:

$$\begin{aligned} \omega_j &= \{i : A_{j,i} \neq 0\}, & E_j &= X_{:, \omega_j} - DA_{:, \omega_j} + d_j A_{j, \omega_j}, \\ E_j &= U \Sigma V^\top \text{ (numpy.linalg.svd)}, & d_j &\leftarrow u_1, \quad A_{j, \omega_j} \leftarrow \sigma_1 v_1^\top. \end{aligned}$$

La SVD se aplica al residual *restringido* a las señales que usan el átomo, lo que conserva el soporte de A ; por Eckart–Young, $\sigma_1 u_1 v_1^\top$ es la mejor aproximación de rango 1 de E_j , de modo que el error total no aumenta en cada actualización de átomo (verificado en las pruebas unitarias). Un átomo sin uso se reinicializa con la columna de mayor norma del residual $X - DA$, normalizada; si todos los residuales son prácticamente nulos se conserva. Tras la última iteración se recalcula A_{train} con el D final.

3.3 Configuración

$K = 128$ (diccionario sobrecompleto), 1500 parches, 8 iteraciones, $T = 4$, inicialización con columnas no constantes de X_{train} normalizadas (RNG 43). No fue necesaria ninguna contingencia: se usó la configuración deseada ($K=128$, 1500 parches, 8 iteraciones).

4 Entrenamiento

El entrenamiento completo tardó 1.53 s en CPU (límite de 4 hilos BLAS). El MSE de representación pasó de 9.549e-04 con D_{init} a 3.413e-04 con el diccionario final (Tabla 1, Figura 1). Átomos sin uso detectados en total: 0.

Tabla 1: Historial de entrenamiento (MSE tras la actualización del diccionario de cada iteración).

iteración	MSE entrenamiento	tiempo acumulado (s)	átomos sin uso
1	5.604473e-04	0.18	0
2	4.229563e-04	0.35	0
3	3.796942e-04	0.53	0
4	3.638848e-04	0.70	0
5	3.532115e-04	0.88	0
6	3.472041e-04	1.05	0
7	3.399084e-04	1.23	0
8	3.382060e-04	1.40	0

5 Evaluación

Se reconstruye coins limpia y ruidosa ($\sigma = 20/255$, una realización con RNG 44, sin clipping; σ empírica 0.07861). Para cada parche se codifica con OMP ($\leq T_0$ átomos), se restaura la media y




Figura 1: Diccionario inicial (parches de entrenamiento) y diccionario final K-SVD.

se reensambla por promedio de solapamientos, sin clipping. Las métricas se calculan siempre contra la imagen limpia. Verificación previa de métricas: imagen contra sí misma $MSE = 0$, $PSNR = \infty$; diferencia constante 0.1: $MSE = 0.0100$, $PSNR = 20.00$ dB. El tiempo es la mediana de 5 ejecuciones (extracción + OMP + reensamblado).

Tabla 2: Resultados sobre coins 128×128 (961 parches, $K=128$).

entrada	T_0	MSE	PSNR (dB)	coef. activos	tiempo (ms)
ruidosa (sin procesar)	–	0.006179	22.09	–	–
limpia	2	0.002132	26.71	2.00	44.1
limpia	4	0.001264	28.98	4.00	80.7
limpia	8	0.000719	31.43	8.00	150.9
ruidosa	2	0.002784	25.55	2.00	42.3
ruidosa	4	0.002442	26.12	4.00	80.6
ruidosa	8	0.002730	25.64	8.00	149.5

6 Discusión y conclusiones

- Con la imagen limpia, el PSNR crece monótonamente con T_0 (de 26.71 dB con $T_0=2$ a 31.43 dB con $T_0=8$): más átomos representan mejor la señal.
- Con la imagen ruidosa el PSNR no es monótono: el máximo está en $T_0=4$ (26.12 dB). Esto es consistente con un compromiso: con pocos átomos se pierde detalle y con muchos OMP también ajusta parte del ruido (interpretación, no medida directa).
- Frente a la imagen ruidosa sin procesar (22.09 dB), la mejor reconstrucción mejora 4.03 dB. Es una ganancia real pero modesta; no se compara con el estado del arte.
- La actividad dispersa media coincide exactamente con T_0 ; el tiempo de reconstrucción crece con T_0 y la codificación OMP ocupa en promedio el 91% de ese tiempo.

Limitaciones. Una sola imagen de entrenamiento y una de prueba, una realización de ruido, T_0 fijo en vez del criterio de error de [2], sin promedio ponderado con la imagen ruidosa, diccionario aprendido sobre parches limpios de otra imagen, coins redimensionada sin conservar su relación de aspecto, y tiempos medidos en una sola máquina. Los resultados no son comparables directamente con las tablas de los artículos.




Figura 2: Reconstrucciones de la imagen limpia (arriba) y ruidosa (abajo) para cada T_0 .




Figura 3: PSNR frente a T_0 . Línea discontinua: imagen ruidosa sin procesar.

Reproducibilidad. `python run_all.py` regenera todos los productos; `pytest` verifica contratos y reproduce el pipeline en un directorio temporal. Versiones:

```
python: 3.11.16
platform: Linux-7.0.0-34-generic-x86_64-with-glibc2.39
processor: x86_64
numpy: 2.4.6
scipy: 1.17.1
```

scikit-learn: 1.9.1
scikit-image: 0.26.0
matplotlib: 3.11.2
pandas: 3.0.6

Referencias

- [1] M. Aharon, M. Elad, A. Bruckstein. K-SVD: An Algorithm for Designing Overcomplete Dictionaries for Sparse Representation. *IEEE Trans. Signal Processing*, 54(11), 2006. <https://doi.org/10.1109/TSP.2006.881199>
- [2] M. Elad, M. Aharon. Image Denoising Via Sparse and Redundant Representations Over Learned Dictionaries. *IEEE Trans. Image Processing*, 15(12), 2006. <https://doi.org/10.1109/TIP.2006.881969>
- [3] scikit-learn: `sklearn.linear_model.orthogonal_mp`; NumPy: `numpy.linalg.svd`; scikit-image: `skimage.data`, `skimage.metrics`.