

Reconstrucción y eliminación de ruido en imágenes mediante representaciones dispersas y aprendizaje K-SVD

S. D. Vásquez Melgarejo, S. J. Arizmendi Rojas, E. A. Rangel Jiménez y J. A. Sánchez Sánchez

Matemáticas Computacionales
Instituto Nacional de Astrofísica, Óptica y Electrónica
Puebla, México

Abstract—Estudio de la reconstrucción de imágenes a partir de representaciones dispersas sobre un diccionario redundante aprendido. Se implementó un ciclo K-SVD que alterna codificación mediante Orthogonal Matching Pursuit (OMP) y actualización secuencial de átomos mediante descomposición en valores singulares sobre residuos restringidos. El diccionario, de dimensión 64×128 se entrenó con 1500 parches centrados de 8×8 píxeles extraídos de *camera*, la evaluación se efectuó sobre *coins*, que no intervino en el aprendizaje. Se consideró ruido gaussiano aditivo con desviación estándar 20/255 y presupuestos de dispersión $T_0 \in \{2, 4, 8\}$. Para la observación ruidosa, $T_0 = 4$ produjo el mejor resultado: 26.12 dB frente a 22.09 dB de la entrada, equivalente a una reducción del 60.5% en el error cuadrático medio. El experimento muestra el compromiso entre capacidad de representación y ajuste del ruido: al aumentar T_0 de 4 a 8 el PSNR disminuyó 0.48 dB. El alcance es una prueba controlada y reproducible; no constituye una réplica cuantitativa del método de Elad y Aharon ni una comparación con el estado del arte.

Index Terms—K-SVD, Representación Dispersa, Aprendizaje de Diccionarios, OMP, Eliminación de Ruido, Procesamiento de Imágenes.

I. INTRODUCCIÓN

Vamos a considerar a $y = x + n$ como una observación de la imagen desconocida x , contaminada por ruido blanco gaussiano $n \sim \mathcal{N}(0, \sigma^2 I)$. La eliminación de ruido es un problema inverso elemental, una regularización demasiado fuerte suprime los bordes y textura, mientras que un modelo excesivamente flexible reproduce parte de la perturbación. Las representaciones dispersas abordan esta tensión suponiendo que cada parche de una imagen admite una aproximación precisa mediante pocos elementos de un diccionario redundante. A diferencia de la base ortogonal fija, el diccionario puede adaptarse a la estadística del conjunto de entrenamiento y contener estructuras locales como bordes, transiciones y patrones oscilatorios.

El algoritmo K-SVD fue propuesto como una generalización de K-means para aprender diccionarios sobrecompletos bajo restricciones de dispersión [1]. Su operación va alternando entre la estimación de los coeficientes y la actualización de los átomos. Esta última se obtiene como una aproximación óptima de rango uno del residual asociado con cada átomo. Elad y Aharon incorporaron dicho aprendizaje en

un estimador global para la eliminación de ruido, añadiendo un modelo disperso sobre todos los parches solapados de la imagen [2]. La agregación de estimaciones locales evita que haya discontinuidades de bloque y conecta el tratamiento por parches con una función de costo global.

En este trabajo se implementa el núcleo algorítmico de K-SVD en una configuración acotada para CPU. La contribución experimental consiste en: 1) establecer una propuesta reproducible para extracción y ensamblado de parches; 2) implementar la actualización K-SVD sin sustituirla por una rutina genérica de aprendizaje de diccionarios; 3) evaluar el efecto de T_0 sobre las reconstrucciones limpias y las ruidosas; y 4) separar los resultados medidos de las diferencias metodológicas respecto del artículo de referencia. La hipótesis es que una dispersión intermedia mejora la observación ruidosa porque limita la capacidad de OMP para ajustar el ruido sin eliminar en exceso la estructura de la señal.

II. MODELO Y MÉTODO

A. Modelo disperso por parches

Sea $z_i \in \mathbb{R}^m$ un parche vectorizado, con $m = 64$, se representa como:

$$z_i = D\alpha_i + r_i, \quad \|\alpha_i\|_0 \leq T_0, \quad (1)$$

donde $D = [d_1, \dots, d_K] \in \mathbb{R}^{m \times K}$ es el diccionario, α_i contiene los coeficientes y r_i es el residual. Con $K = 128 > m$ la representación es redundante. El problema de aprendizaje para la matriz de ejemplos $X = [z_1, \dots, z_N]$ es:

$$\min_{D, A} \|X - DA\|_F^2 \quad \text{s.a.} \quad \|a_i\|_0 \leq T, \quad \|d_k\|_2 = 1. \quad (2)$$

La restricción ℓ_0 vuelve no convexo el problema conjunto, al existir múltiples combinaciones. Se adopta minimización alternada: OMP que aproxima la etapa dispersa y K-SVD actualiza un átomo por vez. OMP selecciona iterativamente el átomo más correlacionado con el residual y reestima por mínimos cuadrados los coeficientes sobre el soporte activo [3], [4]. En esta implementación T es un máximo de coeficientes por parche, una representación exacta puede terminar antes.

B. Actualización K-SVD

Fijados temporalmente los coeficientes, el residual asociado con el átomo d_k se expresa como:

$$E_k = X - \sum_{j \neq k} d_j a_j^\top = X - DA + d_k a_k^\top. \quad (3)$$

Actualizar d_k sobre todas las columnas destruiría la dispersión porque produciría coeficientes no nulos donde el átomo no se utilizaba. Por ello se define $\Omega_k = \{i : A_{k,i} \neq 0\}$ y se restringe el residual a $E_k^R = E_k(:, \Omega_k)$. Si

$$E_k^R = U \Sigma V^\top, \quad (4)$$

entonces $d_k \leftarrow u_1$ y $A_{k,\Omega_k} \leftarrow \sigma_1 v_1^\top$. El teorema de Eckart-Young asegura que esta pareja minimiza el error de rango uno sobre el soporte fijo. Los átomos sin uso se vuelven a inicializar con la columna de mayor norma de $X - DA$ (no fue necesario activar esta regla en el entrenamiento reportado). A diferencia del método de direcciones óptimas, que actualiza el diccionario completo mediante una solución de mínimos cuadrados [5], K-SVD acopla cada átomo con sus coeficientes mediante una SVD local. [6].

C. Reconstrucción de la imagen

Sea R_i el operador que extrae el parche i . Tras la codificación y reconstrucción de cada parche, se restaura la media que se eliminó durante el preprocesamiento y se promedian las contribuciones en los píxeles solapados. Si $\hat{z}_i = D\hat{\alpha}_i + \mu_i \mathbf{1}$, la implementación calcula:

$$\hat{x}(p) = \frac{\sum_{i:p \in R_i} [R_i^\top \hat{z}_i](p)}{\sum_{i:p \in R_i} 1}. \quad (5)$$

Además el estimador original de [2] incluye un término global de fidelidad a la observación y emplea un criterio de paro de OMP dependiente de σ . Aquí se omiten ambos elementos pues el objetivo es aislar el efecto de un diccionario aprendido y de T_0 . Por esta misma razón, no se aplica *clipping* durante la extracción, ensamblado o evaluación.

D. Relación con el estimador global

La reconstrucción por promedios de (5) puede interpretarse como una etapa de minimización por bloques. En la formulación de Elad y Aharon, la imagen y los coeficientes se estiman en conjunto mediante una función del tipo

$$\min_{x, \{\alpha_i\}} \lambda \|x - y\|_2^2 + \sum_i (\|R_i x - D\alpha_i\|_2^2 + \mu_i \|\alpha_i\|_0). \quad (6)$$

Para los coeficientes fijos, el subproblema en x es cuadrático. Su solución pondera la observación y y las reconstrucciones locales $R_i^\top D\alpha_i$ de acuerdo con la cobertura de cada píxel. En el interior de la imagen, donde la cobertura es aproximadamente uniforme, el operador equivale a promediar parches y combinar el promedio con el dato observado.

La implementación corresponde al límite en que se descarta explícitamente el primer término de (6). Esta decisión evita introducir un parámetro adicional λ , pero cambia el estimador:

toda la salida pertenece a la imagen sintetizada por el diccionario. Si el diccionario no modela una estructura presente en la prueba, el promedio no puede recuperarla a partir de la observación original. Por el contrario, el sesgo del diccionario puede actuar como filtro al impedir que componentes no representables sobrevivan. Esta diferencia es importante para interpretar la mejora de PSNR y descarta una comparación numérica directa con [2].

E. Consideraciones numéricas y costo

La normalización de los átomos elimina la ambigüedad de escala $DA = (DC)(C^{-1}A)$ y mantiene comparables las correlaciones utilizadas por OMP. El centrado por parche separa el componente DC de la textura local, la media se conserva como metadato y no consume un átomo durante la codificación. No se normaliza la energía de cada parche porque al hacerlo asignaría el mismo peso a regiones uniformes y a regiones de alto contraste durante el aprendizaje. Todas las operaciones se realizan en doble precisión para que la prueba de ida y vuelta y las comparaciones de contrato no dependan de errores de cuantización.

Para N señales, K átomos, dimensión m y dispersión T , una implementación directa de OMP requiere correlaciones de orden $O(NmKT)$, además de resolver problemas de mínimos cuadrados pequeños sobre el soporte activo. La actualización K-SVD añade para cada átomo una SVD del residual restringido de tamaño $m \times |\Omega_k|$. El costo real depende del uso de cada átomo y de las optimizaciones BLAS. En este experimento, la codificación domina la reconstrucción, mientras que el tamaño reducido de los parches hace manejables las SVD. El diseño evita formar matrices densas de imagen completa; cada etapa opera sobre matrices de parches con dimensiones registradas en los archivos de configuración.

III. DISEÑO EXPERIMENTAL

A. Datos y preprocesamiento

Se emplearon imágenes estándar de `scikit-image`: *camera* para entrenamiento y *coins* para prueba. Ambas se convirtieron a punto flotante de 64 bits antes del redimensionamiento con interpolación antialias y conservación del rango. *Camera* se llevó a 256×256 y *coins* a 128×128 . Esto evita entrenar con la versión limpia exacta de la imagen evaluada, aunque no establece generalización estadística a una población de imágenes.

Los parches de 8×8 se extrajeron con el paso 4, orden de recorrido por filas y aplanado C. Cada columna se centró restando su media, que se conservó para el ensamblado. De los 3969 parches disponibles en el entrenamiento se descartaron los de norma centrada menor o igual que 10^{-8} y se muestrearon 1500 sin reemplazo con semilla 42. La extracción sobre *coins* produjo 961 parches. La composición de los parches originales recuperó ambas imágenes con error máximo 1.11×10^{-16} , lo que verifica las posiciones, orden de vectorización y la cobertura de bordes.

B. Entrenamiento y protocolo de ruido

El diccionario se inicializó con 128 columnas no constantes del conjunto de entrenamiento, normalizadas y seleccionadas con semilla 43. Después se ejecutaron ocho iteraciones de K-SVD, usando $T = 4$ para OMP y cuatro hilos BLAS en CPU. Al finalizar se recodificó X con el diccionario definitivo así el error reportado va a corresponder a una pareja (D, A) coherente.

Para la prueba ruidosa se añadió una única realización de ruido gaussiano con $\sigma = 20/255 = 0.07843$ y semilla 44. La desviación observada fue 0.07861. Tanto la imagen limpia como la ruidosa se reconstruyeron con $T_0 \in \{2, 4, 8\}$. La referencia fue siempre *coins* limpia y el rango de datos para PSNR se fijó en uno:

$$\text{MSE} = \frac{1}{HW} \|x - \hat{x}\|_F^2, \quad \text{PSNR} = 10 \log_{10} \frac{1}{\text{MSE}}. \quad (7)$$

El tiempo de reconstrucción es la mediana de cinco repeticiones e incluye extracción, OMP y ensamblado, excluye entrenamiento, E/S y figuras. Como controles, una imagen comparada consigo misma produjo MSE cero, y un desplazamiento constante de 0.1 produjo MSE 0.01 y PSNR de 20 dB.

C. Contratos y verificación del software

La matriz de señales sigue la convención de una señal por columna: $X \in \mathbb{R}^{64 \times 1500}$, $D \in \mathbb{R}^{64 \times 128}$ y $A \in \mathbb{R}^{128 \times 1500}$. Las posiciones de los parches son enteras y se validan contra los límites de la imagen. La extracción exige datos finitos, tamaños positivos y un paso no mayor que el parche; el ensamblado rechaza coberturas nulas, formas incompatibles y posiciones fuera de rango. Estas condiciones convierten supuestos matemáticos en errores explícitos y evitan que una transposición o un índice inválido produzcan resultados numéricamente plausibles.

La verificación automatizada comprende 32 pruebas. En preprocesamiento se comprueban forma, orden, centrado, cobertura y reconstrucción exacta; en el modelo se verifican normas unitarias, cota de dispersión, reducción del error durante la actualización de un átomo y coherencia de la recodificación final. La evaluación comprueba identificadores, columnas, semillas, ausencia de recorte y alias compatibles del archivo NPZ. Finalmente, una prueba de integración ejecuta los cuatro bloques en un directorio temporal y valida que los productos de cada etapa sean consumibles por la siguiente. Las advertencias de OMP cuando una señal queda representada exactamente corresponden a la terminación temprana y no invalidan la cota $\|\alpha_i\|_0 \leq T$.

Los notebooks se ejecutaron desde un estado limpio y delegan el cálculo en los módulos de `src`; de ese modo las celdas no mantienen una segunda implementación. Los productos guardados contienen configuración efectiva, semillas, historial de entrenamiento y metadatos del protocolo. Esto es necesario porque dos ejecuciones pueden compartir código, pero diferir si cambian el orden de muestreo, el número de átomos o la política de ruido.



Fig. 1. Diccionarios inicial y final. Cada elemento corresponde a un átomo de 8×8 reescalado únicamente para visualización.




Fig. 2. PSNR en función del presupuesto de dispersión. La línea discontinua corresponde a la observación ruidosa sin procesar.

IV. RESULTADOS

A. Aprendizaje del diccionario

El entrenamiento terminó en 2.09 s. El MSE de representación disminuyó de 9.549×10^{-4} con el diccionario inicial a 3.413×10^{-4} después de recodificar con el diccionario final, una reducción relativa del 64.3%. El MSE posterior a cada actualización de diccionario tomó los valores 5.604, 4.230, 3.797, 3.639, 3.532, 3.472, 3.399 y 3.382, todos multiplicados por 10^{-4} . La evolución fue descendente y ningún átomo quedó sin uso. La Fig. 1 muestra que el aprendizaje conserva patrones suaves e incorpora estructuras orientadas y transiciones locales.

B. Reconstrucción limpia y eliminación de ruido

La Tabla I resume los siete casos. En la entrada limpia, el PSNR aumentó de 26.71 a 31.43 dB al incrementar T_0 de 2 a 8; esto confirma que un soporte mayor reduce el sesgo de representación cuando la señal no contiene ruido añadido. En la entrada ruidosa apareció el comportamiento esperado de regularización implícita: $T_0 = 2$ eliminó ruido pero perdió estructura, $T_0 = 4$ alcanzó 26.12 dB y $T_0 = 8$ descendió a 25.64 dB. El mejor caso mejoró 4.03 dB sobre la observación y redujo el MSE de 0.006179 a 0.002442.

La actividad media coincidió con el presupuesto impuesto, por lo que los casos probados no terminaron anticipadamente. El tiempo creció aproximadamente con la cantidad de átomos seleccionados: para la entrada ruidosa pasó de 51.9 ms con $T_0 = 2$ a 168.1 ms con $T_0 = 8$. La codificación OMP representó en promedio, el 88% del tiempo de reconstrucción.

TABLA I
RESULTADOS SOBRE *coins* DE 128×128 PÍXELES. LOS TIEMPOS SON MEDIANAS DE CINCO EJECUCIONES.

Entrada	Método	T_0	MSE	PSNR (dB)	Activos medios	Tiempo (ms)
Ruidosa	Identidad	–	0.006179	22.09	–	–
Limpia	K-SVD/OMP	2	0.002132	26.71	2.00	52.2
Limpia	K-SVD/OMP	4	0.001264	28.98	4.00	88.5
Limpia	K-SVD/OMP	8	0.000719	31.43	8.00	179.4
Ruidosa	K-SVD/OMP	2	0.002784	25.55	2.00	51.9
Ruidosa	K-SVD/OMP	4	0.002442	26.12	4.00	94.0
Ruidosa	K-SVD/OMP	8	0.002730	25.64	8.00	168.1

En consecuencia, el costo adicional de una representación más densa no garantiza mejor restauración, como ilustra simultáneamente la curvatura de la serie ruidosa en la Fig. 2.

V. DISCUSIÓN

Los resultados apoyan la interpretación de T_0 como un parámetro que controla un compromiso entre aproximación y rechazo de ruido. Para la señal limpia, una expansión más rica aproxima mejor parches que no pertenecen exactamente al subespacio generado por cuatro átomos. Bajo ruido, el mismo aumento de capacidad permite a OMP seleccionar componentes correlacionadas accidentalmente con la perturbación. La pérdida de 0.48 dB entre $T_0 = 4$ y $T_0 = 8$ es consistente con este mecanismo, aunque una sola realización no permite estimar su variabilidad. En el algoritmo de [2], el soporte se regula mediante un umbral de error asociado a σ y el promedio de parches se combina con la observación mediante un término de fidelidad; por tanto, nuestros valores no deben compararse directamente con los reportados allí.

El diccionario fue entrenado sobre una imagen limpia diferente. Esta elección evita fuga de la referencia de prueba, pero también limita su adaptación al contenido circular y granular de *coins*. Los trabajos de aprendizaje en línea muestran que colecciones mayores pueden producir diccionarios más estables y escalables [7]; el experimento actual no evalúa esa hipótesis. Tampoco se estudian diccionarios DCT, wavelets, BM3D u otros métodos de restauración. La ganancia observada demuestra funcionamiento interno del sistema, no superioridad frente a alternativas.

Existen cuatro amenazas principales a la validez. Primero, una imagen de prueba no representa la diversidad de texturas, bordes y niveles de contraste de una base estándar. Segundo, una sola semilla de ruido no permite intervalos de confianza. Tercero, el redimensionamiento de *coins* a 128×128 altera su relación de aspecto y su espectro espacial. Cuarto, los tiempos dependen de hardware, bibliotecas BLAS y carga del sistema. Una evaluación de posgrado más amplia debería usar varias imágenes, al menos cinco realizaciones por nivel de ruido, varios valores de σ , una selección de hiperparámetros separada de la prueba y comparadores públicos bajo el mismo protocolo.

A. Implicaciones y extensiones experimentales

El barrido de T_0 permite formular una lectura de sesgo y varianza a nivel de parche. Con dos átomos, la clase de

señales representables es reducida y el estimador exhibe mayor sesgo; con ocho, la clase crece y disminuye el error de aproximación limpio, pero aumenta la posibilidad de explicar perturbaciones aleatorias. El máximo observado en cuatro átomos no debe entenderse como un valor universal. Al crecer σ , sería razonable esperar un soporte óptimo menor o un criterio de paro más estricto; con ruido débil, un soporte mayor podría conservar detalles sin penalización apreciable. Comprobar esta interacción requiere un diseño factorial que cruce varios niveles de ruido con varios presupuestos de dispersión.

La dispersión fija también trata por igual parches con distinta complejidad. Una región suave puede quedar representada con uno o dos átomos, mientras que una intersección de bordes puede requerir más. El criterio de error empleado en [2] adapta indirectamente la cardinalidad: OMP se detiene cuando el residual es compatible con la energía de ruido esperada. Una extensión inmediata consistiría en comparar la regla fija con $\|z_i - D\alpha_i\|_2^2 \leq C\sigma^2$, manteniendo el mismo diccionario y protocolo. Tal comparación aislaría si la mejora proviene de adaptar el soporte o de cambiar simultáneamente otras partes del estimador.

También es conveniente estudiar el término de fidelidad de (6). La salida actual depende por completo de la síntesis $D\alpha_i$, por lo que los detalles fuera del diccionario se pierden aun cuando estén respaldados por la observación. Incorporar el promedio ponderado con y produciría una familia continua entre la reconstrucción dispersa y el dato medido. El parámetro no debería elegirse sobre la imagen de prueba; se estimaría en un conjunto de validación o se vincularía analíticamente con σ . La comparación debe conservar arreglos sin recorte para evitar que la saturación artificial modifique el MSE.

Finalmente, la incertidumbre experimental debe cuantificarse. Para cada imagen y nivel de ruido se ejecutarían varias semillas, reportando media, desviación estándar e intervalos de confianza del PSNR. Una prueba pareada usaría exactamente las mismas realizaciones para todos los valores de T_0 y para los métodos de referencia. Además del PSNR, SSIM podría describir preservación estructural, aunque no reemplaza la inspección de residuos y artefactos. Esta ampliación convertiría la demostración actual en una evaluación comparativa; el código modular y las semillas explícitas proporcionan la base para realizarla sin alterar los contratos existentes.




Fig. 3. Reconstrucciones para las entradas limpia (fila superior) y ruidosa (fila inferior). La visualización se limita a $[0, 1]$, pero los arreglos empleados para las métricas permanecen sin recorte.

VI. REPRODUCIBILIDAD Y DIVISIÓN DEL TRABAJO

Todos los arreglos numéricos usan `float64`; las señales se almacenan por columnas y las semillas de datos, modelo y ruido son 42, 43 y 44, respectivamente. El módulo `src/preprocesamiento.py` es la única implementación de extracción y ensamblado; los notebooks importan los módulos compartidos. El flujo completo puede regenerarse con `python run_all.py`; las pruebas cubren formas, finitud, normas, dispersión, contratos de archivos y reproducción integral. El código y los productos finales se conservan en el repositorio del proyecto de SarahVasquezM [8].

La responsabilidad se dividió por contratos: Sarah preparó entorno, datos, parches y ensamblado; Alan implementó OMP, K-SVD y entrenamiento; Sergio ejecutó ruido, reconstrucciones y métricas; Areli integró los artefactos y la comunicación científica. Esta separación evita implementaciones duplicadas y hace explícita la procedencia de cada resultado.

VII. CONCLUSIONES

Se obtuvo una implementación funcional de K-SVD para parches de imagen, con actualización de átomos mediante SVD restringida y codificación OMP. El diccionario redujo el error de representación de entrenamiento en 64.3%. Sobre la observación ruidosa, $T_0 = 4$ proporcionó la mejor restauración, con 26.12 dB y una ganancia de 4.03 dB respecto de la entrada. El deterioro observado al usar ocho átomos confirma que una mayor fidelidad de representación no equivale necesariamente a mejor eliminación de ruido. La principal conclusión metodológica es que el presupuesto de dispersión debe seleccionarse considerando el nivel de ruido y validarse sobre un conjunto independiente. Los resultados son reproducibles dentro del protocolo descrito, pero su generalización requiere ampliar imágenes, semillas, niveles de ruido y métodos de comparación.

REFERENCES

- [1] M. Aharon, M. Elad, and A. Bruckstein, "K-SVD: An algorithm for designing overcomplete dictionaries for sparse representation," *IEEE Trans. Signal Process.*, vol. 54, no. 11, pp. 4311–4322, Nov. 2006, doi: 10.1109/TSP.2006.881199.
- [2] M. Elad and M. Aharon, "Image denoising via sparse and redundant representations over learned dictionaries," *IEEE Trans. Image Process.*, vol. 15, no. 12, pp. 3736–3745, Dec. 2006, doi: 10.1109/TIP.2006.881969.
- [3] Y. C. Pati, R. Rezaifar, and P. S. Krishnaprasad, "Orthogonal matching pursuit: Recursive function approximation with applications to wavelet decomposition," in *Proc. 27th Asilomar Conf. Signals, Systems and Computers*, 1993, pp. 40–44.
- [4] S. G. Mallat and Z. Zhang, "Matching pursuits with time-frequency dictionaries," *IEEE Trans. Signal Process.*, vol. 41, no. 12, pp. 3397–3415, Dec. 1993.
- [5] K. Engan, S. O. Aase, and J. H. Husøy, "Method of optimal directions for frame design," in *Proc. IEEE ICASSP*, 1999, vol. 5, pp. 2443–2446.
- [6] R. Rubinstein, A. M. Bruckstein, and M. Elad, "Dictionaries for sparse representation modeling," *Proc. IEEE*, vol. 98, no. 6, pp. 1045–1057, Jun. 2010.
- [7] J. Mairal, F. Bach, J. Ponce, and G. Sapiro, "Online dictionary learning for sparse coding," in *Proc. 26th Int. Conf. Machine Learning*, 2009, pp. 689–696.
- [8] SarahVasquezM, "K-SVD Image Denoising," GitHub repository, 2026. [Online]. Available: <https://github.com/SarahVasquezM/ksvd-image-denoising>. Accessed: Oct. 5, 2026.