

Reconstrucción y eliminación de ruido en imágenes con K-SVD

Reporte final de implementación y auditoría técnica

Proyecto académico de Matemáticas Computacionales · Integración final: Sarah Vásquez M. · 3 de octubre de 2026

Resumen

Se implementó una adaptación didáctica de K-SVD para aprender un diccionario sobre parches 8×8 de camera y reconstruir coins, una imagen no usada en entrenamiento. El pipeline usa OMP de scikit-learn, actualizaciones de átomos con `numpy.linalg.svd` y una única implementación modular. En la imagen ruidosa con $\sigma=20/255$, el mejor caso fue $T_0=4$ con 26.12 dB, una mejora de 4.03 dB frente a la entrada ruidosa. La auditoría local ejecutó los cuatro bloques, 32 pruebas y los cuatro notebooks sin errores.

Objetivo y alcance

El objetivo es estudiar cómo la dispersión controla el compromiso entre representación y ajuste de ruido. No se busca reproducir todos los detalles del estimador del artículo ni competir con métodos actuales. La evidencia se limita a una imagen de prueba, una realización de ruido y tres valores fijados de T_0 .

Diseño experimental

Componente	Decisión	Control
Datos	camera 256×256 / coins 128×128	Prueba separada del entrenamiento
Parches	8×8 , paso 4, centrados	Señales por columnas, float64
Modelo	$K=128$, 8 iteraciones, $T=4$	CPU, semillas 42/43/44
Evaluación	$T_0=2, 4, 8$; $\sigma=20/255$	MSE, PSNR, actividad y tiempo

Contribución de Sarah. El bloque de datos se conservó como fuente de verdad y se reforzó con validaciones de finitud, tipos, posiciones, cobertura y parámetros inválidos. Los arrays coinciden exactamente con el paquete privado entregado en Kaggle.

1 Datos y representación por parches

Las imágenes de scikit-image se convierten con `img_as_float64` antes del redimensionamiento. De camera se extraen 3969 parches; los 1500 parches de entrenamiento se eligen sin reemplazo con RNG 42. Coins produce 961 parches y permanece fuera del aprendizaje.

Entrenamiento: camera 256x256



Prueba: coins 128x128



Figura 1. Imágenes de entrenamiento y prueba después del redimensionamiento.

Cada parche x_i se centra como $z_i = x_i - \mu_i \mathbf{1}$ y se almacena como una columna de 64 elementos en orden C. La media μ_i se conserva para el reensamblado. El control extraer $\rightarrow$ restituir media $\rightarrow$ ensamblar recuperó ambas imágenes con error máximo 1.11×10^{-16} .

2 Codificación dispersa y K-SVD

Para un diccionario $\text{DER}^{64 \times 128}$, OMP obtiene coeficientes a_i con a lo más T entradas activas. En cada iteración K-SVD se alternan la codificación y la actualización de cada átomo. Para el átomo j se restringe el residual a las señales que lo usan, se calcula $E_j = U \Sigma V^T$ y se asignan $d_j = u_j$ y $a_j, \omega = \sigma_1 v_1^T$. Esta SVD entrega la mejor aproximación de rango uno sobre el soporte fijo.

- OMP: `sklearn.linear_model.orthogonal_mp`; las paradas tempranas documentadas significan que T es un máximo.
- SVD: `numpy.linalg.svd` sobre el residual restringido; no se usa `DictionaryLearning`.
- Los parches y reconstrucciones permanecen en float64 y no se aplica clipping.

3 Entrenamiento del diccionario

La configuración completa se ejecutó sin contingencia: $K=128$, 1500 parches, 8 iteraciones y $T=4$. El MSE de entrenamiento bajó de $9.549\text{e-}04$ con el diccionario inicial a $3.413\text{e-}04$ con el diccionario final recodificado. El tiempo local fue 2.09 s y depende de la máquina.



Figura 2. Diccionario inicial y diccionario aprendido, 128 átomos de 8×8 .




Figura 3. Error de representación después de cada actualización K-SVD.

La curva desciende en las ocho iteraciones medidas. No se interpreta el aspecto visual de cada átomo como una métrica de calidad; la evidencia principal es el error de representación y la evaluación sobre coins.

4 Resultados de reconstrucción

Todas las métricas usan la imagen coins limpia como referencia y data_range=1.0. La entrada ruidosa obtuvo 22.09 dB. El mejor resultado ruidoso fue T0=4 con 26.12 dB y MSE 0.002442.

Entrada	T0	MSE	PSNR dB
ruidosa sin procesar	—	0.006179	22.09
limpia	2	0.002132	26.71
limpia	4	0.001264	28.98
limpia	8	0.000719	31.43
ruidosa	2	0.002784	25.55
ruidosa	4	0.002442	26.12
ruidosa	8	0.002730	25.64




Figura 4. Referencia, entrada ruidosa y reconstrucciones para T0=2, 4 y 8.

En la imagen limpia, el PSNR aumenta al permitir más átomos. En la imagen ruidosa el máximo ocurre en T0=4: con T0=2 se pierde detalle y con T0=8 OMP también representa parte del ruido. Esta última explicación es una interpretación consistente con la curva, no una medición causal independiente.

5 Conclusiones, auditoría y limitaciones

- La mejor reconstrucción ruidosa mejora 4.03 dB sobre la entrada; la ganancia es real para este caso y no se presenta como estado del arte.
- El pipeline conserva los contratos esenciales: columnas float64, diccionario normalizado, máximo de coeficientes activos y ensamblado sin clipping.
- La auditoría corrigió alias del contrato de evaluación sin retirar los nombres usados por la integración existente.
- Las cuatro matrices del dataset son idénticas, elemento a elemento, a las del paquete aceptado de Sarah.

Reproducibilidad

La evidencia local incluye python run_all.py, 32 pruebas y ejecución limpia de los cuatro notebooks. El bloque 1 también cuenta con una versión privada Successful en Kaggle CPU; la ejecución completa de los cuatro bloques no se atribuye a Kaggle. Los tiempos cambian entre equipos, mientras que datos, métricas y reconstrucciones se reproducen salvo redondeo de álgebra lineal.

Limitaciones

Sólo se usa una imagen de entrenamiento, una imagen de prueba, una semilla de modelo y una realización de ruido. No existe conjunto de validación ni se comparan otros algoritmos. El barrido $T0 \in \{2, 4, 8\}$ fue fijado antes de ejecutar; por tanto, el resultado sirve como prueba de concepto y no como estimación generalizable.

Referencias

- [1] Aharon, M., Elad, M. y Bruckstein, A. (2006). K-SVD: An Algorithm for Designing Overcomplete Dictionaries for Sparse Representation. IEEE Transactions on Signal Processing, 54(11). <https://doi.org/10.1109/TSP.2006.881199>
- [2] Elad, M. y Aharon, M. (2006). Image Denoising Via Sparse and Redundant Representations Over Learned Dictionaries. IEEE Transactions on Image Processing, 15(12). <https://doi.org/10.1109/TIP.2006.881969>
- [3] scikit-learn. orthogonal_mp. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.orthogonal_mp.html
- [4] NumPy. numpy.linalg.svd. <https://numpy.org/doc/stable/reference/generated/numpy.linalg.svd.html>
- [5] scikit-image. Data and metrics APIs. <https://scikit-image.org/docs/stable/api/>